

PREDICTION COUTS MEDICAUX

DES

Jan 13, 2026



MACHINE
REGRESSION

LEARNING

I- Contexte et Objectifs



Contexte

Dans le secteur de la santé, la maîtrise et l'anticipation des coûts médicaux représentent un enjeu majeur pour les compagnies d'assurance, les organismes de gestion de la santé et les décideurs publics. Les dépenses médicales présentent une forte hétérogénéité entre individus, influencée par des facteurs démographiques, comportementaux et géographiques, tels que l'âge, l'indice de masse corporelle (IMC), le statut de fumeur ou encore la région de résidence.

Avec la disponibilité croissante des données de santé et l'essor des techniques de machine learning, il devient possible d'exploiter ces informations afin de mieux comprendre les déterminants des coûts médicaux et de développer des modèles prédictifs capables d'estimer les charges individuelles. Ces outils permettent non seulement d'améliorer la prise de décision, mais aussi de renforcer la planification et l'optimisation des ressources de santé.

Dans ce contexte, ce projet s'inscrit dans une démarche de valorisation des données de santé par l'analyse statistique et le machine learning, allant de l'exploration des données jusqu'au déploiement opérationnel d'un modèle de prédiction.

Objectifs

Objectif général

L'objectif principal de cette étude est de **concevoir et déployer un modèle de machine learning capable de prédire les coûts médicaux individuels** à partir de caractéristiques socio-démographiques et médicales, dans une logique à la fois analytique et opérationnelle.

Objectifs spécifiques

- analyser et comprendre la structure des données de coûts médicaux à travers une analyse exploratoire approfondie ;
- identifier les variables explicatives les plus influentes sur les charges médicales ;
- comparer plusieurs modèles de régression afin de sélectionner le plus performant et le plus robuste ;
- intégrer le modèle retenu dans un pipeline reproductible de prétraitement et de prédiction ;
- déployer le modèle sous forme d'une API accessible via une infrastructure cloud, permettant une utilisation concrète du système de prédiction.

Problématique du projet

La validation de notre solution passe par la réponse technique et métier à la question suivante

Comment concevoir un modèle de machine learning fiable et robuste permettant de prédire les coûts médicaux individuels à partir de données socio-démographiques, tout en assurant son intégration dans une solution opérationnelle accessible et reproductible ?



Glossaire des termes clés

Cette section définit les concepts techniques fondamentaux qui soutiennent et structurent l'architecture de ce projet.

Analyse Exploratoire des Données (EDA)	Étape initiale d'un projet de data science consistant à explorer, visualiser et résumer les données afin de comprendre leur structure, détecter des anomalies et orienter les choix de modélisation.
Variable cible (Target)	Variable que le modèle cherche à prédire. Dans ce projet, il s'agit des charges médicales , représentant le coût total des soins pour un individu.
Variables explicatives (Features)	Ensemble des variables utilisées comme entrées du modèle pour expliquer ou prédire la variable cible (âge, IMC, statut de fumeur, région, etc.).
Pipeline de Machine Learning	Chaîne structurée regroupant l'ensemble des étapes de traitement des données (prétraitement, encodage, normalisation) et le modèle de prédiction, garantissant la cohérence entre l'entraînement et l'inférence.
Sur-apprentissage (Overfitting)	Phénomène où un modèle s'adapte excessivement aux données d'entraînement, ce qui entraîne de mauvaises performances sur de nouvelles données non observées.
Jeu d'entraînement et jeu de test	Subdivision du jeu de données initial permettant d'entraîner le modèle (jeu d'entraînement) et d'évaluer sa capacité de généralisation (jeu de test), généralement selon un ratio 80/20.
Métriques d'évaluation	Indicateurs quantitatifs utilisés pour mesurer les performances du modèle. Dans ce projet, les métriques calculées sont le RMSE , le MAE et le R² . La principale est le RMSE .
API (Application Programming Interface)	Interface logicielle permettant à des applications ou utilisateurs d'interagir avec le modèle de prédiction, notamment pour envoyer des données en entrée et recevoir une prédiction en sortie.

La section suivante présente la démarche méthodologique adoptée pour la mise en œuvre de cette étude, en détaillant successivement les étapes de préparation des données, de modélisation et de déploiement du modèle de prédiction.

II– Explorative Data Analysis (EDA)



1. Objectifs de l'analyse exploratoire

L'analyse exploratoire des données (EDA) constitue une étape fondamentale du projet de prédiction des coûts médicaux. Elle vise à comprendre la structure du jeu de données, à identifier les caractéristiques principales des variables, à détecter d'éventuelles anomalies et à mettre en évidence les relations entre la variable cible et les variables explicatives. Cette étape permet également d'orienter les choix de prétraitement et de modélisation ultérieurs.

2. Présentation générale des données

Le jeu de données utilisé regroupe des informations socio-démographiques et médicales individuelles, incluant notamment l'âge, l'indice de masse corporelle (IMC), le nombre d'enfants, le sexe, le statut de fumeur, la région de résidence et les charges médicales associées.

La variable cible de l'étude est **charges**, représentant le coût total des dépenses médicales par individu.

3. Préparation initiale des données

Avant toute analyse, une phase de préparation a été menée afin de garantir la qualité des données :

- suppression des éventuelles colonnes dupliquées ;
- conversion explicite des variables numériques vers des formats adaptés ;
- gestion des valeurs manquantes, en particulier pour les variables catégorielles, où une modalité spécifique "Manquant" a été introduite lorsque nécessaire.

Cette étape assure la cohérence des analyses statistiques et graphiques réalisées par la suite.


4. Analyse univariée des variables numériques

L'analyse univariée des variables numériques repose sur des statistiques descriptives classiques (moyenne, médiane, écart-type), complétées par des indicateurs de forme de distribution tels que la **skewness** et la **kurtosis**.

Les variables **âge** et **IMC** présentent des distributions quasi-symétriques et proches de la normalité, indiquant qu'aucune transformation spécifique n'est nécessaire pour leur utilisation en modélisation. Leur variabilité reste modérée, suggérant un échantillon globalement représentatif.

En revanche, la variable **charges** montre une forte asymétrie positive et une dispersion très élevée. Cette distribution est caractérisée par une majorité de coûts modérés et quelques valeurs extrêmement élevées, traduisant une hétérogénéité importante des dépenses médicales entre individus. Cette observation justifie l'utilisation ultérieure de transformations (notamment logarithmiques) afin d'améliorer la stabilité et les performances des modèles prédictifs.

La variable **children**, de nature discrète, présente une distribution asymétrique typique des variables de comptage, avec une concentration sur les valeurs faibles.



5. Analyse des variables catégorielles

L'analyse des variables catégorielles repose sur l'étude de leur répartition à l'aide de diagrammes circulaires et d'effectifs relatifs.

Les variables **sexe**, **statut de fumeur** et **région** présentent une distribution globalement équilibrée, garantissant une représentation suffisante de chaque modalité dans le jeu de données.

Cette étape permet de vérifier l'absence de déséquilibres majeurs susceptibles de biaiser l'apprentissage des modèles.

6. Analyse bivariable : variable cible et variables explicatives

L'analyse bivariable vise à étudier la relation entre les charges médicales et les différentes variables explicatives.

Les visualisations de type **boxplots** et **violins** mettent en évidence des différences marquées de coûts médicaux selon certaines catégories. En particulier, le statut de fumeur apparaît comme un facteur déterminant, avec des charges nettement plus élevées et plus dispersées chez les fumeurs.

Les autres variables catégorielles, telles que le sexe ou la région, montrent des écarts plus modérés, suggérant un effet moins prononcé sur les coûts.

7. Analyse des corrélations

Une matrice de corrélation basée sur le coefficient de Pearson a été construite pour les variables numériques.

Cette analyse met en évidence des corrélations faibles à modérées entre certaines variables explicatives, sans multicollinéarité excessive. La variable **charges** présente des corrélations limitées avec les variables numériques prises isolément, confirmant la nécessité de recourir à des modèles capables de capturer des relations non linéaires et combinées.

8. Tests statistiques

Afin de confirmer les observations issues des visualisations, des tests statistiques ont été réalisés :

- **ANOVA**, pour comparer les moyennes entre groupes lorsque les hypothèses de normalité sont raisonnablement vérifiées ;
- **test de Kruskal-Wallis**, méthode non paramétrique adaptée en présence de distributions asymétriques.

Les résultats des tests confirment des différences significatives entre certains groupes pour la variable cible charges. Le statut de fumeur ressort très nettement comme un facteur discriminant majeur : l'ANOVA comme le test de Kruskal-Wallis sont hautement significatifs, conduisant au rejet clair de l'hypothèse d'égalité des groupes.

Pour la variable sexe, l'ANOVA indique une différence significative entre les groupes, tandis que le test de Kruskal-Wallis ne confirme pas ce résultat. Cette divergence suggère un effet faible et sensible aux hypothèses de normalité, indiquant que l'influence du sexe sur les charges reste limitée.

Enfin, concernant la région, l'ANOVA met en évidence une différence statistiquement significative, mais celle-ci n'est pas validée par le test non paramétrique. Cela suggère que les écarts observés entre régions sont modestes et peu robustes.

9. Analyse multivariée

Des **pairplots** ont été utilisés pour explorer simultanément les relations entre plusieurs variables numériques, en tenant compte des catégories. Cette approche permet de visualiser les tendances globales, les regroupements potentiels et la dispersion des données, en complément des analyses univariées et bivariées.


10. Enseignements clés et implications pour le prétraitement

L'EDA met en évidence plusieurs éléments structurants pour la suite du projet :

- la variable cible **charges** présente une forte asymétrie, nécessitant une transformation adaptée ;
- certaines variables catégorielles, notamment le statut de fumeur, jouent un rôle majeur dans l'explication des coûts médicaux ;
- l'absence de multicolinéarité forte permet l'utilisation de modèles de régression variés.

Ces résultats orientent directement les choix de **prétraitement**, de **sélection de modèles** et de **stratégies d'évaluation** adoptés lors de la phase de modélisation.

III – MODELING



1. Objectif de la modélisation

L'objectif de cette phase est de développer un modèle de machine learning capable de **prédire les coûts médicaux individuels (charges)** à partir des caractéristiques socio-démographiques et médicales des assurés.

Cette étape vise à transformer les enseignements issus de l'analyse exploratoire des données (EDA) en un **outil prédictif robuste**, performant et exploitable dans un environnement de production via une API.

2. Préparation des données pour la modélisation

À la suite de l'EDA, les variables explicatives retenues comprennent à la fois :

- des **variables numériques** telles que l'âge, l'indice de masse corporelle (IMC) et le nombre d'enfants ;
- des **variables catégorielles** telles que le sexe, le statut de fumeur et la région.

Afin d'assurer la cohérence du processus de modélisation, les traitements suivants ont été intégrés dans un **pipeline de prétraitement** :

- séparation explicite des variables explicatives et de la variable cible (charges) ;
- encodage des variables catégorielles à l'aide de techniques adaptées (One-Hot Encoding) ;
- mise à l'échelle des variables numériques (standardisation) pour les modèles sensibles aux différences d'échelle ;
- intégration de l'ensemble de ces étapes dans un pipeline unique afin d'éviter toute fuite d'information (data leakage).

3. Séparation des jeux de données

Le jeu de données a été divisé en deux sous-ensembles distincts :

- **80 % des données** ont été utilisées pour l'entraînement des modèles ;
- **20 % des données** ont été réservées au test.

Ce découpage permet d'évaluer de manière objective la capacité de généralisation des modèles sur des données non observées lors de l'apprentissage.

4. Modèles évalués

Plusieurs modèles de régression ont été entraînés et comparés afin d'identifier celui offrant les meilleures performances :

- **Régression linéaire**, utilisée comme modèle de référence (baseline) ;
- **Modèles pénalisés** (Ridge, Lasso, Elastic Net), permettant de limiter le sur-apprentissage et de gérer la multicolinéarité ;
- **Modèles non linéaires**, notamment basés sur les arbres de décision et les méthodes d'ensemble, capables de capturer des relations plus complexes entre les variables explicatives et les coûts médicaux.

Chaque modèle a été évalué dans un cadre homogène, en utilisant le même pipeline de prétraitement.

Un feature engineering a aussi été fait en créant la variable `is_obese` à partir de l'IMC et plusieurs méthodes de scaling ont été mises en place.

Un OneHot encoding a aussi été fait pour les variables catégorielles.

5. Méthodes d'évaluation des performances

Les performances des modèles ont été mesurées à l'aide de métriques adaptées aux problèmes de régression :

- **RMSE (Root Mean Squared Error)**, sensible aux erreurs de grande amplitude ;

- **MAE (Mean Absolute Error)**, plus robuste aux valeurs extrêmes ;
- **R² (coefficient de détermination)**, indiquant la proportion de variance expliquée par le modèle.

Ces indicateurs ont été calculés sur le jeu d'entraînement et sur le jeu de test afin de détecter d'éventuels phénomènes de sur-apprentissage.

La métrique principale est le **RMSE**, de formule suivante :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Le choix de cette métrique se justifie d'une part par le fait qu'il pénalise les grosses erreurs, et d'autre part par le fait que la MAPE et la MAE gèrent les outliers, lesquels ont déjà été pris en compte par la transformation logarithmique.

6. Sélection du modèle final


Le modèle final a été retenu sur la base :

- de ses **performances sur le jeu de test** ;
- de la **stabilité des résultats** entre les jeux d'entraînement et de test ;
- de sa **capacité à être intégré facilement dans une API de prédiction**.

Ce choix garantit un bon compromis entre précision prédictive, robustesse et complexité du modèle.

Le pipeline final dans notre cas a été le suivant.

Pipeline de Machine Learning



7. Sauvegarde et exploitation du modèle

Une fois le modèle sélectionné, l'ensemble du pipeline (prétraitement et modèle) a été **sérialisé au format .joblib**.

Cette sérialisation permet :

- de réutiliser directement le modèle sans réentraînement ;
- d'assurer une cohérence totale entre la phase d'apprentissage et la phase de prédiction ;
- de faciliter l'intégration du modèle dans l'API développée avec FastAPI.
-


8. Conclusion de la phase de modélisation

La phase de modélisation a permis de construire un modèle de prédiction fiable des coûts médicaux, fondé sur une démarche rigoureuse et reproductible.

Le recours à des pipelines, à un découpage clair des données (80 % entraînement / 20 % test) et à une comparaison systématique des modèles assure la solidité des résultats obtenus.

Cette étape constitue une transition naturelle vers la **mise en production du modèle**, réalisée via une API déployée sur le cloud, permettant l'utilisation opérationnelle du système de prédiction.

IV– Deployment



1. Objectif de la plateforme

L'objectif de cette plateforme est de **mettre à disposition un modèle de machine learning entraîné pour la prédiction des coûts médicaux**, via une **API REST** accessible en ligne.


Cette API permet à un utilisateur ou à une application externe d'envoyer des caractéristiques individuelles (features) et d'obtenir en retour une **prédiction du coût médical estimé**.

2. Choix technologiques

La solution repose sur les technologies suivantes :

- **FastAPI** : framework Python léger et performant pour la création d'API REST.
- **Pydantic** : utilisé pour la validation et la structuration des données en entrée de l'API.
- **Scikit-learn** : pour l'entraînement du modèle et la construction du pipeline de traitement.
- **Joblib** : pour la sérialisation et le chargement du pipeline de machine learning.
- **Render** : plateforme cloud utilisée pour l'hébergement et le déploiement de l'API.
- **GitHub** : gestion du code source et intégration continue avec Render.

Pipeline de Déploiement



3. Structure de l'API

3.1 Définition des données d'entrée (Pydantic)

Les données envoyées à l'API sont définies à l'aide de **Pydantic**, via une classe (par exemple Features).

Cette classe décrit précisément :

- les variables attendues (âge, IMC, nombre d'enfants, statut fumeur, région, etc.),
- leur type (entier, float, chaîne de caractères),
- et garantit que les données reçues sont **conformes avant toute prédiction**.

Ce mécanisme permet d'éviter les erreurs de format et sécurise l'utilisation du modèle.

4. Intégration du modèle de machine learning

Le modèle utilisé correspond au **meilleur modèle sélectionné lors de la phase de modélisation**.

- Le modèle est stocké sous la forme d'un fichier **.joblib**.
- Ce fichier contient **un pipeline complet**, incluant :
 - le prétraitement des données (encodage, transformation),
 - la normalisation éventuelle,
 - le modèle final de prédiction.

Lors du démarrage de l'API, ce pipeline est chargé en mémoire et utilisé directement pour effectuer les prédictions, ce qui garantit une **cohérence totale entre l'entraînement et l'inférence**.

5. Routes de l'API

Deux routes principales ont été définies :

5.1 Route /health

- Rôle : vérifier que l'API est bien fonctionnelle.
- Fonctionnement :
 - lorsqu'un utilisateur accède à /health, l'API renvoie un message de type **"status: OK"**.
- Utilité :
 - surveillance de l'état du service,
 - diagnostic rapide en cas de problème.

5.2 Route /predict

- Rôle : effectuer la prédiction des coûts médicaux.
- Fonctionnement :
 1. l'utilisateur envoie une requête contenant les features au format attendu,
 2. l'API transmet ces données au pipeline chargé,
 3. le modèle calcule la prédiction,
 4. l'API renvoie la valeur prédite au format JSON.


Toutes les requêtes de prédiction passent exclusivement par cette route.

6. Déploiement sur Render

6.1 Connexion au dépôt GitHub

Le dépôt GitHub contenant le code de l'API a été **connecté directement à Render**.

À chaque mise à jour du code sur la branche principale, Render est capable de relancer automatiquement le déploiement.



6.2 Création du service web

Sur Render :

- un **Web Service** a été créé,
- l'environnement d'exécution est **Python 3**,
- le service porte le nom **Medical-cost-prediction**,
- la région de déploiement est **Virginia**.

Une fois le service déployé, une **URL publique** est générée, permettant d'accéder directement à l'API.

6.3 Statut et fonctionnement

Les images montrent que :

- le service est bien **déployé avec succès (status : Deployed)**,
- l'API est accessible via une URL publique,
- une instance gratuite est utilisée (avec un possible délai au premier appel après inactivité).

7. Qualité du code et bonnes pratiques (Du côté des tests unitaires avec les Git Actions)

Le projet respecte les **bonnes pratiques Python**, notamment :

- conventions de nommage,
- limitation du nombre de caractères par ligne,

- imports structurés,
- conformité aux règles **PEP8**.

Un outil de linting est utilisé pour détecter :

- les erreurs de syntaxe,
- les variables non définies,
- les incohérences dans la structure du code.

Des tests unitaires spécifiques pourraient être ajoutés ultérieurement pour vérifier le bon comportement des fonctions critiques (chargement du modèle, prédiction, format de sortie).

8. Conclusion

Cette plateforme propose une **chaîne complète et cohérente** allant :

1. de la sélection du meilleur modèle de machine learning,
2. à son intégration dans une API robuste avec FastAPI,
3. jusqu'à son déploiement effectif sur le cloud via Render.

L'API permet désormais d'exploiter le modèle de prédiction des coûts médicaux de manière **automatisée, fiable et accessible**, constituant ainsi une base solide pour une application web ou un service décisionnel.

Livrables

 [Lien vers le repository GitHub du projet](#)

 [Lien vers le modèle déployé](#)

 [Lien vers la présentation](#)

Ce document a été rédigé par :

Mamady I BERETE

Khadidiatou COULIBALY

G. Judicaël Oscar KAFANDO

Ahmadou NIASS

Samba SOW



Documentation
technique

Health Cost