



Prediction

Par :
Mamady I BERETE
Khadidiatou COULIBALY, Judicaël Oscar
Kafando, Ahmadou NIASS, Samba SOW

Sous la supervision de :
Mme Mously DIAW,
Senior Freelance ML Engineer



Plan


Contexte et problématique

Explorative Data Analysis

Modeling

Déploiement

Contexte et Problématique



Un acte médical ne coûte jamais “au hasard”.

Derrière chaque consultation, chaque hospitalisation ou chaque traitement, se cachent des facteurs bien réels : l’âge, le mode de vie, l’état de santé, le contexte médical.

Pourtant, pour les compagnies d’assurance, ces coûts restent souvent difficiles à anticiper avec précision. Résultat : des risques financiers élevés, des politiques de couverture complexes, et une pression croissante sur les tarifs.

Chez **Health Cost**, nous faisons le pari que les données racontent une histoire — et que le Machine Learning permet de la comprendre. Notre projet vise à transformer ces données en prévisions fiables, pour aider les assureurs à mieux décider, mieux planifier et mieux protéger.

La question :

“Comment peut-on exploiter les données socio-démographiques et médicales des assurés pour prédire, de manière fiable et automatisée, le coût des soins médicaux, afin d’aider les compagnies d’assurance à mieux anticiper leurs dépenses et gérer leurs risques ?”

Explorative Data Analysis (EDA)

Dataset overview

Source : Kaggle

1338 lignes, 7 colonnes.

Les variables : age, sex, bmi, children, smoker, region, charges.

Variable cible : charges

Qualité des données

Statistiques descriptives et analyses univariée, bivariée, multivariée, tests d'ANOVA, de Kruskal Wallis.


Features and target variables

- age : Âge du bénéficiaire principal
- sex : Sexe du contractant (male / female)
- bmi : Indice de masse corporelle (kg/m²)
- children : Nombre d'enfants à charge couverts par l'assurance
- smoker : Indique si le bénéficiaire est fumeur (yes / no)
- region : Région de résidence aux États-Unis (northeast, southeast, southwest, northwest)
- charges : Coûts médicaux individuels facturés par l'assurance (variable cible)


Les analyses

L'EDA a consisté à vérifier les valeurs manquantes et doublons, analyser les distributions et outliers, étudier les corrélations entre variables et visualiser les relations clés avec des graphiques simples (histogrammes, boxplots, heatmaps). Cela a permis d'obtenir une vue d'ensemble claire sur la structure et les tendances du jeu de données.


Quelques statistiques descriptives



49,5% de femmes




De no smokers



Par région

Insights issus de l'EDA

- Suppression des doublons
- Variable cible : forte asymétrie positive, une dispersion élevée et la présence de valeurs extrêmes
- Faire une transformation logarithmique
- Faire un One-Hot encoding
- Possibilité de créer une variable is_obese à partir de bmi
- Feature scaling pour les modèles sensibles à l'échelle



Distribution de la variable cible

Modeling

Modèles entraînés

- Régressions pénalisées : Lasso, Ridge, ElasticNet.
- Régression linéaire : Linear Regression.
- Méthodes à noyau / distance : KNN, SVR
- Arbre de décision : Decision Tree.
- Ensembles (ensemblistes) : Random Forest, Gradient Boosting, XGBoost.

Métrique principale

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Pistes de modélisation

- Feature scaling divers.
- One Hot encoding avec toutes nouvelles variables ou en supprimant l'une.
- Ajout ou non de is_obese.


Justification de la métrique

Le choix de cette métrique se justifie d'une part par le fait qu'il pénalise les grosses erreurs, et d'autre part par le fait que la MAPE et la MAE gèrent les outliers, lesquels ont déjà été pris en compte par la transformation logarithmique.

Meilleur modèle

Gradient Boost


Feature importance




SHapley Additive exPlanations (SHAP) pour le modèle SVR

Si l'on regarde du côté de la MAE, le meilleur modèle est le **SRV**, qui est un modèle de boîte noire (black box).

Ainsi, pour faire voir le feature importance, on utilise l'algorithme **SHapley Additive exPlanations (SHAP)**.




Le pipeline final



Déploiement

Pipeline de Déploiement



L'interface

Lien vers le repository Github